



UNIVERSITAS INDONESIA

**DATA ANALISIS DAN PREDIKSI FATALITAS KECELAKAAN LALU LINTAS
DI PUERTO RICO PERIODE 2017-2020**

KELOMPOK 9

Heidi Renata Halim - 2006596320

Piawai Said Umbara - 1806235933

Yusuf Fakhri Aldrian - 1906351096

-

-

**FAKULTAS ILMU KOMPUTER
PROGRAM STUDI ILMU KOMPUTER
DEPOK
MARET 2023**

DAFTAR ISI

DAFTAR ISI	ii
DAFTAR GAMBAR	iv
DAFTAR TABEL	v
DAFTAR KODE PROGRAM	vi
DAFTAR LAMPIRAN	vii
1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Definisi Permasalahan	2
1.3 Tujuan Penelitian	2
2 STUDI LITERATUR	3
2.1 Kecelakaan	3
2.1.1 Definisi Kecelakaan	3
2.1.2 Jenis dan Bentuk Kecelakaan	3
2.1.2.1 Berdasarkan Korban Kecelakaan	4
2.1.2.2 Berdasarkan Lokasi Kejadian	4
2.1.2.3 Berdasarkan Waktu Terjadinya Kecelakaan	4
2.1.2.4 Berdasarkan Posisi Kecelakaan	5
2.1.2.5 Berdasarkan Jumlah Kendaraan yang Terlibat	5
2.1.3 Faktor-faktor Penyebab Kecelakaan Lalu Lintas	5
2.1.3.1 Faktor Pemakai Jalan	6
2.1.3.2 Faktor Kendaraan	7
2.1.3.3 Faktor Jalan	9
2.1.3.4 Faktor Lingkungan	10
2.2 Teknik Penambangan Data	11
2.2.1 One-Way ANOVA	11
2.2.1.1 Konsep Dasar One-way ANOVA	11
2.2.1.2 Uji Hipotesis dalam One-way ANOVA	11
2.2.1.3 Interpretasi Hasil Uji	12
2.3 Analisis Literatur Terkait	12
2.3.1 Analisis Kecelakaan Lalu Lintas Jalan Raya di Kota Semarang Menggunakan Metode K-Means Clustering	13
2.3.2 A Road Accident Prediction Model Using Data Mining Techniques	14
3 METODOLOGI	16
3.1 Penjelasan Dataset	16
3.2 Teknik Analisis Data	20

3.2.1	Regresi Linier	20
3.2.1.1	Metrik Evaluasi	22
3.2.2	Regresi Random Forest	25
3.2.2.1	Cara kerja	25
4	EKSPERIMEN DAN EVALUASI	27
4.1	Eksperimen dan Evaluasi	27
4.1.1	Korelasi Kecelakaan yang Melibatkan Alkohol dengan Waktu Kejadian	27
4.1.1.1	Hasil One-Way ANOVA	29
4.1.1.2	Evaluasi Data	30
4.1.2	Distribusi Fatalitas kecelakaan yang terjadi pada jenis jalan dan daerah berbeda	31
4.1.2.1	Evaluasi Data	34
4.1.3	Faktor-faktor yang berpengaruh besar dalam kecelakaan yang melibatkan pejalan kaki dan seberapa jauh faktor-faktor ini dapat memprediksi jumlah pejalan kaki yang terlibat?	34
4.1.3.1	Faktor-faktor yang berpengaruh besar dalam kecelakaan yang melibatkan pejalan kaki	34
4.1.3.2	Seberapa jauh faktor-faktor ini dapat memprediksi jumlah pejalan kaki yang terlibat?	37
4.1.4	Atribut-atribut yang Dapat Memprediksi Angka Kematian	37
4.1.4.1	Evaluasi Model	39
5	KESIMPULAN DAN SARAN	40
5.1	Kesimpulan	40
5.2	Saran	42
	DAFTAR REFERENSI	44

DAFTAR GAMBAR

Gambar 2.1.	Arsitektur implementasi model	15
Gambar 3.1.	Diagram cara kerja regresi random forest	26
Gambar 4.1.	Persebaran data kecelakaan yang melibatkan alkohol pada bulan yang berbeda	27
Gambar 4.2.	Variasi jumlah kecelakaan yang melibatkan alkohol yang pada tanggal yang berbeda	28
Gambar 4.3.	Salah satu grafik residual hasil ANOVA Test yang menunjukkan antar kecelakaan mabuk dengan jam terjadinya kecelakaan	29
Gambar 4.4.	Perbandingan total fatalitas yang terjadi antara Urban dan Rural . . .	31
Gambar 4.5.	Rata-rata fatalitas yang terjadi pada tipe jalan yang berbeda	32
Gambar 4.6.	Total fatalitas yang terjadi pada tipe jalan yang berbeda	33

DAFTAR TABEL

Tabel 3.2.	Data Dictionary	20
Tabel 4.1.	Koefisien Korelasi	36
Tabel 4.2.	Koefisien Korelasi	38

DAFTAR KODE PROGRAM

DAFTAR LAMPIRAN

Lampiran 1. Contoh Lampiran	46
---------------------------------------	----

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Berdasarkan Pasal 1 ayat 24 Undang-Undang Nomor 22 Tahun 2009 tentang Lalu Lintas dan Angkutan Jalan, kecelakaan lalu lintas dapat didefinisikan sebagai peristiwa yang terjadi di jalan raya yang tidak diduga dan tidak disengaja. Sejarah mencatat bahwa kecelakaan lalu lintas pertama kali terjadi pada 31 Agustus 1869 melibatkan seorang Imuwan Irlandia bernama Mary Ward yang meninggal ketika dia jatuh dari mobil uap sepupunya dan ditabrak olehnya. Dari definisinya sendiri saja, dapat dipastikan bahwa kecelakaan lalu lintas pasti merupakan kecelakaan yang terjadi di jalan raya dan lalu lintas dan pasti melibatkan suatu kendaraan bermotor karena esensi keberadaan lalu lintas yang ada untuk mengatur kendaraan. Berdasarkan seorang pakar dari UGM, Iwan Puja Riyadi, ada 4 faktor utama yang menyebabkan kecelakaan pada lalu lintas antara lain, kondisi jalan, kondisi alam atau cuaca saat itu, kondisi kendaraan yang digunakan oleh pengemudi dari segi rem, dan banyaknya muatan yang dibawa oleh kendaraan.

Selain daripada faktor yang sudah disebutkan diatas, ada satu faktor penyebab kecelakaan lainnya yang harus diketahui, yaitu faktor kesalahan manusia, ada kalanya ketika seseorang seharusnya tidak boleh menyetir kendaraan seperti saat mabuk atau dibawah pengaruh obat-obatan tetapi mereka tetap melakukannya. Meskipun kecelakaan yang terjadi setelahnya tidak disengaja, kita tetap pengemudi yang berada dibawah pengaruh obat atau alkohol akan tetap bisa dituntut pertanggungjawabannya karena pada dasarnya, pengaruh obat atau minuman beralkohol dapat mempengaruhi jalan pikiran dan persepsi seseorang menjadi kacau dan tidak rasional, sehingga memperbesar kemungkinan dari orang itu untuk menyebabkan kecelakaan.

Mengingat kecelakaan lalu lintas adalah permasalahan yang serius dan seringkali menyebabkan kerugian yang cukup besar, maka dibutuhkan analisis data tentang berbagai macam kecelakaan yang terjadi dan identifikasi faktor penyebabnya agar dapat diambil suatu tindakan preventif yang dapat mengurangi terjadinya kecelakaan di masa depan. Informasi yang akurat mengenai faktor pemicu terjadinya kecelakaan lalu lintas sangat

dibutuhkan oleh pihak kepolisian sebagai bahan pertimbangan dan pengawasan. Menggunakan pendekatan *machine learning*, kita dapat menemukan pola-pola dari kecelakaan yang terjadi. Kemudian, dari pola-pola ini, dapat dilakukan pencegahan tambahan secara eksternal seperti pengaturan jam lalu lintas atau penerapan larangan tertentu. Pada beberapa penelitian sebelumnya, model *machine learning* berguna untuk melakukan identifikasi pada faktor yang paling berpengaruh menyebabkan kecelakaan dan memprediksi keparahan kecelakaan yang terjadi di masa depan.

1.2 Definisi Permasalahan

Kelompok kami memutuskan untuk mengambil dataset kecelakaan yang terjadi di Puerto Rico pada interval waktu antara 2019-2020. Berikut adalah rumusan permasalahan dari penelitian yang dilakukan:

- Apakah ada hubungan yang signifikan antara waktu dalam satu hari atau hari dalam seminggu dengan kemungkinan terjadinya kecelakaan yang melibatkan mabuk dalam mengemudi?
- Bagaimana perbedaan tipe jalan (*urban vs. rural, route type*, atau *functional system*) mempengaruhi fatalitas dalam kecelakaan?
- Apa faktor yang berpengaruh besar dalam kecelakaan yang melibatkan pejalan kaki dan apakah faktor-faktor ini dapat memprediksi jumlah pejalan kaki yang terlibat dalam kecelakaan?
- Apakah angka dari fatalities dari suatu kecelakaan dapat diprediksi dengan atribut-atribut tertentu?

1.3 Tujuan Penelitian

Tujuan penelitian ini adalah untuk mengetahui apakah berdasarkan analisis yang dibuat menggunakan *machine learning* faktor dan prediksi yang didapatkan akan memiliki kemiripan dengan faktor yang sudah dipaparkan sebelumnya. Penelitian ini juga bertujuan untuk mencari pola entah itu waktu atau lokasi jalan dari kecelakaan yang terjadi sehingga bisa dilakukan pencegahan atau penanganan tambahan dari pola yang sudah ditemukan.

BAB 2

STUDI LITERATUR

2.1 Kecelakaan

2.1.1 Definisi Kecelakaan

Dalam melakukan suatu analisis mengenai kecelakaan lalu lintas diperlukan pengetahuan mengenai definisi dari kecelakaan lalu lintas itu sendiri. Berdasarkan Pasal 1 ayat 24 Undang-Undang Nomor 22 Tahun 2009 tentang Lalu Lintas dan Angkutan Jalan yang dimaksud dengan kecelakaan lalu lintas adalah suatu peristiwa di jalan yang tidak diduga dan tidak disengaja melibatkan kendaraan dengan atau tanpa pengguna jalan lain yang mengakibatkan korban manusia dan/atau kerugian harta benda.

Sementara pasal 93 ayat 1 Peraturan Pemerintah No. 43 Tahun 1993 tentang Prasarana Jalan Raya dan Lalu Lintas mendefinisikan kecelakaan lalu lintas sebagai suatu peristiwa di jalan raya yang tidak disangka-sangka dan tidak disengaja, melibatkan kendaraan dengan atau tanpa pemakai jalan lainnya, mengakibatkan korban manusia atau kerugian harta benda. Korban kecelakaan lalu lintas dapat berupa korban mati, luka berat dan luka ringan dan diperhitungkan paling lama 30 (tiga puluh) hari setelah kecelakaan terjadi.

Berdasarkan pengertian yang telah dijabarkan sebelumnya, dapat ditarik kesimpulan bahwa kecelakaan lalu lintas merujuk pada suatu peristiwa tak terduga yang terjadi di jalan raya dan melibatkan kendaraan bermotor serta pengguna jalan lainnya, yang dapat menimbulkan kerusakan serta mengakibatkan korban manusia seperti cedera ringan, cedera berat, dan bahkan kematian.

2.1.2 Jenis dan Bentuk Kecelakaan

Jenis dan bentuk kecelakaan dapat diklasifikasikan menjadi lima, yaitu: kecelakaan berdasarkan korban kecelakaan, kecelakaan berdasarkan lokasi kejadian, kecelakaan berdasarkan waktu terjadinya kecelakaan, kecelakaan berdasarkan posisi kecelakaan dan kecelakaan berdasarkan jumlah kendaraan yang terlibat. Penjelasan mengenai klasifikasi jenis dan bentuk kecelakaan tersebut diuraikan lebih lanjut.

2.1.2.1 Berdasarkan Korban Kecelakaan

Kecelakaan berdasarkan korban kecelakaan menitikberatkan pada manusia itu sendiri, terdiri dari kecelakaan dengan luka ringan, luka berat maupun meninggal dunia. Pasal 93 Peraturan Pemerintah No. 43 Tahun 1993 tentang Prasarana dan Lalu Lintas Jalan mengklasifikasikan korban kecelakaan sebagai berikut:

1. Kecelakaan luka fatal atau meninggal

Korban meninggal atau korban mati adalah korban yang dipastikan mati sebagai akibat kecelakaan lalu lintas dalam waktu paling lama 30 hari setelah kecelakaan tersebut.

2. Kecelakaan luka berat

Korban luka berat adalah korban yang karena luka-lukanya menderita cacat tetap atau harus dirawat dalam jangka waktu lebih dari 30 hari sejak terjadinya kecelakaan. Yang dimaksud cacat tetap adalah apabila sesuatu anggota badan hilang atau tidak dapat digunakan sama sekali dan tidak dapat sembuh/pulih untuk selamanya.

3. Kecelakaan luka ringan

Korban luka ringan adalah keadaan korban mengalami luka-luka yang tidak membahayakan jiwa dan/atau tidak memerlukan pertolongan atau perawatan lebih lanjut di rumah sakit.

2.1.2.2 Berdasarkan Lokasi Kejadian

Kecelakaan dapat terjadi di berbagai tempat di sepanjang ruas jalan, baik pada jalan lurus, tikungan jalan, tanjakan dan turunan, di dataran atau di pegunungan, di dalam kota maupun di luar kota.

2.1.2.3 Berdasarkan Waktu Terjadinya Kecelakaan

Kecelakaan berdasarkan waktu terjadinya kecelakaan dapat digolongkan menjadi dua, yaitu:

1. Jenis hari

- Hari kerja: Senin, Selasa, Rabu, Kamis, dan Jum'at

- Hari libur: Hari-hari libur nasional
- Akhir minggu: Sabtu dan Minggu

2. Waktu

- Dini hari: Pukul 00.00 - 06.00
- Pagi hari: Pukul 06.00 - 12.00
- Siang hari: Pukul 12.00 - 18.00
- Malam hari: Pukul 18.00 - 24.00

2.1.2.4 Berdasarkan Posisi Kecelakaan

Kecelakaan jika dikategorikan dari posisi tabrakan dapat dibagi menjadi:

1. Tabrakan pada saat menyalip (*Side Swipe*)
2. Tabrakan depan dengan samping (*Right Angle*)
3. Tabrakan muka dengan belakang (*Rear End*)
4. Tabrakan muka dengan muka (*Head On*)
5. Tabrakan dengan pejalan kaki (*Pedestrian*)
6. Tabrak lari (*Hit and Run*)
7. Tabrakan diluar kendali (*Out of Control*)

2.1.2.5 Berdasarkan Jumlah Kendaraan yang Terlibat

Kecelakaan dapat dikategorikan berdasarkan jumlah kendaraan yang terlibat, yakni kecelakaan tunggal yang melibatkan satu kendaraan, kecelakaan ganda yang melibatkan dua kendaraan, atau kecelakaan beruntun yang melibatkan lebih dari dua kendaraan.

2.1.3 Faktor-faktor Penyebab Kecelakaan Lalu Lintas

Kecelakaan dapat disebabkan oleh kurang efektifnya satu/lebih faktor-faktor berikut: pe-makai jalan (manusia), lingkungan, jalan, dan kendaraan.

2.1.3.1 Faktor Pemakai Jalan

Pemakai jalan merupakan unsur yang terpenting dalam lalu lintas karena manusia sebagai pemakai jalan merupakan unsur utama adanya pergerakan lalu lintas. Pemakai jalan adalah semua orang yang menggunakan fasilitas langsung dari satu jalan. Faktor manusia sebagai pengguna jalan dapat dibagi menjadi dua golongan, yaitu:

1. Pengemudi, termasuk pengemudi kendaraan tak bermotor.
2. Pejalan kaki, termasuk para pedagang asongan, pedagang kaki lima, dan lain-lain.

2.1.3.1.1 Faktor Pengemudi

Berdasarkan Pasal 1 Peraturan Pemerintah No. 44 Tahun 1993 tentang Kendaraan dan Pengemudi, pengemudi adalah orang yang mengemudikan kendaraan bermotor atau orang yang secara langsung mengawasi calon pengemudi yang sedang belajar mengemudikan kendaraan bermotor. Pengemudi kendaraan baik kendaraan bermotor maupun tidak bermotor merupakan penyebab kecelakaan yang utama sehingga sangat perlu diperhatikan. Tingkah laku pribadi pengemudi dalam arus lalu lintas adalah faktor yang menentukan karakteristik lalu lintas yang terjadi. Bertambahnya usia atau orang yang lebih tua akan lebih banyak mengalami kecelakaan karena refleks pengemudi menjadi lebih lambat dan kemampuan fisik tertentu akan menurun. Reaksi dalam mengemudi erat hubungannya dengan kondisi fisik manusia (*Human Phisycal Factor*), dari penerima rangsangan setelah melihat suatu tanda (rambu) hingga pengambilan keputusan/respons.

1. *Perception*, yaitu pengamatan atas rangsangan yang diterima panca indera.
2. *Identification*, yaitu penelaahan terhadap rangsangan dari panca indera.
3. *Emotion* atau *Judgement*, yaitu proses pengambilan keputusan untuk menentukan reaksi yang sesuai (misalnya, berhenti, menyalip, menepi, atau membunyikan klakson).
4. *Violation*, yaitu pengambilan tindakan yang membutuhkan koordinasi dengan kendaraan, misalnya menginjak pedal rem, banting setir, dan lainnya.

Total waktu yang diperlukan untuk melaksanakan pengamatan (*Perception*) hingga pada reaksi (*Violation*) sering disebut sebagai PIEV Time. PIEV Time 2,5 detik digunakan

untuk menentukan jarak berhenti yang aman untuk setiap tingkat kecepatan dan PIEV Time 2,0 detik digunakan untuk jarak pandang di persimpangan jalan.

2.1.3.1.2 Faktor Pejalan Kaki

Pejalan kaki sebagai salah satu unsur pengguna jalan dapat menjadi korban kecelakaan dan dapat pula menjadi penyebab kecelakaan. Pejalan kaki sangat mudah mengalami cedera serius atau kematian jika ditabrak oleh kendaraan bermotor. Pelayanan terhadap pejalan kaki perlu mendapat perhatian yang optimal, yaitu dengan cara memisahkan antara kendaraan dan pejalan kaki, dapat menurut ruang ataupun waktu, sehingga kendaraan dan pejalan kaki berada pada tempat yang aman. Pemisahan ini dapat dilakukan dengan menyediakan fasilitas trotoar untuk mencegah agar pejalan kaki tidak berjalan secara reguler di sepanjang jalan.

Menurut World Health Organization, setiap tahunnya, lebih dari 270000 pejalan kaki kehilangan nyawa mereka di jalan-jalan di dunia. Secara global, pejalan kaki menyumbang 22% dari total kematian di jalan. Jutaan orang terluka dalam kecelakaan lalu lintas terkait dengan pejalan kaki, beberapa yang menjadi cacat permanen. Kapasitas untuk merespon keselamatan pejalan kaki merupakan komponen penting dari upaya untuk mencegah kecelakaan lalu lintas jalan.

2.1.3.2 Faktor Kendaraan

Kendaraan adalah alat yang dapat bergerak di jalan, terdiri dari kendaraan bermotor dan kendaraan tidak bermotor. Menurut Pasal 1 Peraturan Pemerintah No. 44 Tahun 1993 tentang Kendaraan dan Pengemudi, kendaraan bermotor adalah kendaraan yang digerakkan oleh peralatan teknik yang berada pada kendaraan itu. Kendaraan bermotor dapat dikelompokkan dalam beberapa jenis, yaitu: sepeda motor, mobil penumpang, mobil bus, mobil barang dan kendaraan khusus. Kendaraan adalah dasar sistem lalu lintas yang memerlukan interaksi antara pengguna, kendaraan dan lingkungan jalan.

Menurut Peraturan Pemerintah No. 44 Tahun 1993 tentang Kendaraan dan Pengemudi, setiap kendaraan bermotor harus dilengkapi dengan peralatan pengereman yang meliputi rem utama dan rem parkir dan memiliki sistem roda yang meliputi roda-roda dan sumbu roda. Roda-roda tersebut berupa pelek-pelek dan ban-ban hidup serta sumbu atau gabungan sumbu-sumbu roda yang dapat menjamin keselamatan. Di samping sistem roda, kendaraan bermotor juga harus memiliki suspensi berupa penyangga yang

mampu menahan beban, getaran dan kejutan untuk menjamin keselamatan dan perlindungan terhadap penggunaanya. Lampu-lampu tambahan pada kendaraan bermotor bisa mengurangi resiko kecelakaan. Perlengkapan lampu-lampu dan alat pemantul cahaya pada kendaraan bermotor harus meliputi lampu utama dekat secara berpasangan, lampu utama jauh secara berpasangan, lampu penunjuk arah secara berpasangan di bagian depan dan bagian belakang kendaraan, lampu rem secara berpasangan, lampu posisi depan secara berpasangan, lampu mundur, lampu penerangan tanda nomor kendaraan di bagian belakang kendaraan, lampu isyarat peringatan bahaya, dan lampu tanda batas secara berpasangan. Sabuk pengaman berjumlah dua atau lebih yang dipasang untuk melengkapi tempat duduk pengemudi dan tempat duduk penumpang.

Faktor penyebab kecelakaan dari sisi kendaraan antara lain:

1. Penyebab kecelakaan dari sisi perlengkapan kendaraan, yaitu:
 - (a) Alat-alat rem tidak bekerja dengan baik.
 - (b) Alat-alat kemudi tidak bekerja dengan baik.
 - (c) Ban atau roda dalam kondisi buruk.
 - (d) Tidak ada kaca spion.
2. Penyebab kecelakaan dari sisi penerangan kendaraan, yaitu:
 - (a) Syarat lampu penerangan tidak terpenuhi.
 - (b) Menggunakan lampu yang menyilaukan.
 - (c) Lampu tanda rem tidak bekerja.
3. Penyebab kecelakaan dari sisi pengamanan kendaraan, misalnya karoseri kendaraan yang tidak memenuhi syarat keamanan.
4. Penyebab kecelakaan dari sisi mesin kendaraan, misalnya mesin tiba-tiba mogok di jalan.
5. Karena hal-hal lain dari kendaraan, contohnya:
 - (a) Muatan kendaraan terlalu berat untuk truk dan lain-lain.
 - (b) Perawatan kendaraan yang kurang baik (persneling blong, kemudi patah dan lain-lain).

2.1.3.3 Faktor Jalan

Sifat dan kondisi jalan sangat berpengaruh sebagai penyebab kecelakaan lalu lintas. Ahli jalan raya dan ahli lalu lintas merencanakan jalan dengan cara yang benar dan perawatan secukupnya dengan harapan keselamatan didapatkan. Perencanaan tersebut berdasarkan pada hasil analisa fungsi jalan, volume dan komposisi lalu lintas, kecepatan rencana, topografi, faktor manusia, berat dan ukuran kendaraan, lingkungan sosial, serta jumlah dana. Penyimpangan dari standar perencanaan dan kriteria perencanaan jalan bagi suatu ruas jalan hanya akan mengakibatkan turunnya nilai aman ruas jalan tersebut. Bila dalam pelaksanaan terpaksa menyimpang dari ketentuan yang standar, maka informasi rawan kecelakaan harus segera dipasang sebelum suatu jalan dibuka untuk umum. Selain itu, pada lokasi rawan harus diberi informasi yang jelas mengenai kondisi jalan tersebut sehingga pengemudi mengetahui kondisi sekitarnya dan lebih berhati-hati. Informasi tersebut dapat berupa *delineator* (garis pembatas jalan) yang khusus digunakan pada waktu malam hari dan dilengkapi dengan cat yang dapat memantulkan cahaya, tonggak di tepi jalan, mata kucing dan marka dengan cat yang dapat memantulkan cahaya.

Jalan sebagai landasan bergeraknya kendaraan harus direncanakan sedemikian rupa agar memenuhi syarat keamanan dan kenyamanan bagi pemakainya. Perencanaan geometrik jalan harus memperhatikan lalu lintas yang akan melewati jalan tersebut, kelandaian jalan, alinyemen horizontal, persilangan dan komponen pada penampang melintang.

Faktor yang disebabkan oleh faktor jalan dapat diklasifikasikan sebagai berikut:

1. Kecelakaan lalu lintas yang disebabkan oleh perkerasan jalan:
 - (a) Lebar perkerasan yang tidak memenuhi syarat.
 - (b) Permukaan jalan yang licin dan bergelombang.
 - (c) Permukaan jalan yang berlubang.
2. Kecelakaan lalu lintas yang disebabkan oleh alinyemen jalan:
 - (a) Tikungan yang terlalu tajam.
 - (b) Tanjakan dan turunan yang terlalu curam.
3. Kecelakaan lalu lintas yang disebabkan oleh pemeliharaan jalan:
 - (a) Jalan rusak.

- (b) Perbaiki jalan yang menyebabkan kerikil dan debu berserakan.
- 4. Kecelakaan lalu lintas yang disebabkan oleh penerangan jalan:
 - (a) Tidak adanya lampu penerangan jalan pada malam hari.
 - (b) Lampu penerangan jalan yang rusak dan tidak diganti.
- 5. Kecelakaan lalu lintas yang disebabkan oleh rambu-rambu lalu lintas:
 - (a) Rambu ditempatkan pada tempat yang tidak sesuai.
 - (b) Rambu lalu lintas yang ada kurang atau rusak.
 - (c) Rambu lalu lintas yang ada kurang atau rusak.

2.1.3.4 Faktor Lingkungan

1. Lokasi jalan

- (a) Di dalam kota, misalnya di daerah pasar, pertokoan, perkantoran, sekolah, perumahan dan lain sebagainya.
- (b) Di luar kota, misalnya di daerah datar, pedesaan, pegunungan, dan sebagainya.

2. Iklim atau Musim

Indonesia mengalami dua macam musim, yaitu musim penghujan dan musim kemarau, hal ini menjadi perhatian bagi pengemudi agar selalu waspada dalam mengemudikan kendaraannya. Selain itu, adanya pergantian waktu dari pagi, siang, sore dan malam hari memberikan intensitas cahaya yang berbeda-beda. Hal tersebut mempengaruhi keadaan jalan yang terang, gelap atau remang-remang. sehingga mempengaruhi penglihatan pengemudi sewaktu mengendarai kendaraannya.

3. Volume lalu lintas

Arus atau volume lalu lintas pada suatu jalan raya diukur berdasarkan jumlah kendaraan yang melewati titik tertentu selama selang waktu tertentu. Volume lalu lintas dinyatakan dengan Lalu lintas Harian Rata-rata Pertahun atau disebut juga AADT (*Average Annual Daily Traffic*) atau LHR (Lalu lintas Harian Rata-rata) bila periode pengamatan kurang dari satu tahun. Kapasitas jalan dapat bervariasi secara substansial tergantung pada volume kendaraan atau pengguna jalan lainnya. Ini berarti model rekayasa lalu lintas atau tindakan tidak dapat diterapkan tanpa analisis yang cermat dari kondisi setempat.

2.2 Teknik Penambangan Data

Dataset kecelakaan di <https://www.nhtsa.gov/file-downloads?p=nhtsa/downloads/FARS/> adalah kumpulan data dari Sistem Pelaporan Analisis dan Informasi Kecelakaan Jalan Raya (FARS) yang disediakan oleh Administrasi Keselamatan Lalu Lintas Jalan Raya Nasional (NHTSA) di Amerika Serikat. Dataset ini mencakup informasi tentang kecelakaan jalan raya yang melibatkan kendaraan bermotor dan non-motor di Amerika Serikat mulai dari tahun 1975 hingga 2020. Data yang terdapat dalam dataset meliputi informasi tentang jenis kendaraan, waktu dan lokasi kecelakaan, jumlah korban, jenis cedera yang dialami, dan faktor-faktor penyebab kecelakaan seperti alkohol, kecepatan, dan cuaca. Dataset ini digunakan untuk menganalisis pola dan tren kecelakaan jalan raya serta untuk mengembangkan solusi untuk meningkatkan keselamatan dan mencegah kecelakaan di masa depan.

2.2.1 One-Way ANOVA

One-way ANOVA adalah teknik analisis data yang digunakan untuk membandingkan rata-rata antara tiga atau lebih kelompok yang independen. Teknik ini sangat berguna dalam penelitian di berbagai bidang seperti ilmu sosial, kesehatan, ekonomi, dan sebagainya. Pada bab ini, akan dijelaskan secara detail tentang konsep dasar One-way ANOVA, cara melakukan uji hipotesis, dan interpretasi hasil uji.

2.2.1.1 Konsep Dasar One-way ANOVA

Pada One-way ANOVA, variabel independen yang menjadi faktor yang mempengaruhi variabel dependen atau hasil pengamatan, dibagi menjadi tiga atau lebih kelompok atau kategori. Variabel dependen kemudian diukur dalam setiap kelompok tersebut dan rata-rata hasil pengamatan dihitung. Tujuan dari analisis ini adalah untuk menentukan apakah ada perbedaan signifikan antara rata-rata hasil pengamatan di setiap kelompok.

2.2.1.2 Uji Hipotesis dalam One-way ANOVA

Uji hipotesis dalam One-way ANOVA dilakukan untuk menentukan apakah perbedaan antara rata-rata hasil pengamatan di setiap kelompok signifikan secara statistik. Hipotesis yang diajukan adalah sebagai berikut:

- H0: Tidak ada perbedaan signifikan antara rata-rata hasil pengamatan di setiap kelompok.
- H1: Ada perbedaan signifikan antara rata-rata hasil pengamatan di setiap kelompok. Tingkat signifikansi atau alpha yang umum digunakan dalam analisis ini adalah 0,05 atau 0,01. Apabila p-value kurang dari alpha yang ditentukan, maka H0 akan ditolak dan H1 diterima.

2.2.1.3 Interpretasi Hasil Uji

Setelah melakukan uji hipotesis, hasilnya dapat diinterpretasikan sebagai berikut:

1. Apabila p-value kurang dari alpha yang ditentukan, maka terdapat perbedaan signifikan antara rata-rata hasil pengamatan di setiap kelompok. Hal ini menunjukkan bahwa faktor yang mempengaruhi variabel dependen memiliki pengaruh signifikan terhadap hasil pengamatan.
2. Apabila p-value lebih besar dari alpha yang ditentukan, maka tidak terdapat perbedaan signifikan antara rata-rata hasil pengamatan di setiap kelompok. Hal ini menunjukkan bahwa faktor yang mempengaruhi variabel dependen tidak memiliki pengaruh signifikan terhadap hasil pengamatan.
3. Selain itu, interpretasi hasil juga dapat dilakukan dengan melihat nilai F-ratio dan sumbu kuadrat. Nilai F-ratio yang besar menunjukkan adanya perbedaan yang signifikan antara kelompok, sementara sumbu kuadrat menunjukkan jumlah variasi dalam data.

2.3 Analisis Literatur Terkait

Untuk memulai penelitian, dibutuhkan kerangka berpikir yang sesuai untuk permasalahan yang ingin dipecahkan. Untuk membentuk kerangka berpikir yang sesuai, perlu dikaitkan dengan hasil studi literatur yang telah dilakukan. Oleh karena itu, pada bab ini, akan dijelaskan hasil studi literatur yang telah dilakukan yang telah dikaitkan dengan kerangka kerja untuk penelitian ini.

2.3.1 Analisis Kecelakaan Lalu Lintas Jalan Raya di Kota Semarang Menggunakan Metode K-Means Clustering

Makalah ini disusun oleh Muhammad Syaeful Fajar pada tahun 2015. Pada makalah ini, peneliti melakukan analisis terhadap data kecelakaan yang terjadi pada lalu lintas jalan raya Polrestabes Semarang tahun 2014. Penelitian pada makalah ini dilakukan oleh penulis dengan pendekatan Research and Development metode k-means clustering. Selain data yang didapat dari lalu lintas Semarang, penulis juga mendapatkan data dari laporan kecelakaan Jawa Tengah tahun 2006-2014.

Tujuan dari penelitian penulis adalah untuk mengetahui faktor penyebab kecelakaan, memprediksi waktu kejadian kecelakaan berdasarkan faktor-faktor yang berkaitan, mengetahui atau memperkirakan umur pelaku kecelakaan, dan yang terutama, mengusulkan penanganan yang tepat atas hasil analisis data. Peneliti awalnya mengumpulkan data melalui kombinasi observasi, wawancara, dan literasi. Kemudian, penulis melakukan analisis dan pemilihan data secara manual menggunakan Microsoft Excel.

Model yang dirancang oleh penulis ada 2 jenis, yaitu model yang menggunakan sistem simple random sampling dan model yang menggunakan analogy based estimation. Analogy based estimation menggunakan batasan biaya yang digunakan dalam proyek sebagai batasan dari pembuatan model. Proses yang dirancang oleh penulis kurang lebih sama dengan yang selama ini kita lakukan dalam memproses data. Penulis pertama melakukan preprocessing data dan pemilihan data, kemudian menentukan jumlah variabel input dan jumlah cluster yang akan dibuat. Dari jumlah cluster yang sudah ditentukanlah kemudian penulis membuat sistem yang akan menghitung dan mengelompokan tiap data berdasarkan centroid yang nanti akan ditentukan oleh model. Model kemudian melakukan iterasi untuk menemukan centroid yang paling maksimal dari semuanya.

Hasilnya, penulis berhasil mengklasifikasikan beberapa kluster usia pelaku dan korban. Kluster pertama terdiri atas pelaku anak di bawah umur dan golongan lansia (usia non-produktif), kluster kedua berisi sebagian besar pelaku dan korban dengan usia produktif dan beberapa yang tidak diketahui, dan kluster ketiga diisi oleh pemuda pelajar yang berasal dari golongan SMP dan SMA. Dari ketiga kluster yang didapat, ditarik kesimpulan juga bahwa kendaraan yang banyak terlibat pada semua kluster adalah kendaraan roda 2, hal ini juga dipengaruhi oleh kondisi Kota Semarang yang didominasi oleh motor. Seperti yang dilakukan oleh penulis, kita dapat menggunakan machine learning

dalam contoh ini adalah k-means untuk menentukan penyebab kecelakaan terbanyak dan kendaraan yang paling banyak terlibat. Penulis juga mendapatkan bahwa sebagian besar kecelakaan yang terjadi pada tiap kluster diakibatkan oleh faktor manusia. Data kesimpulan dari makalah ini dimanfaatkan kebanyakan oleh anggota kepolisian dan pemerintah untuk menerapkan aturan yang lebih baik untuk meminimalisir kecelakaan.


2.3.2 A Road Accident Prediction Model Using Data Mining Techniques

Ditulis oleh Dhanya Viswanath; Preethi K; Nandini R; Bhuvaneshwari R, studi ini dilakukan untuk mencari pola kejadian kecelakaan tersebut dapat dijadikan sebagai data untuk membuat prediksi terkait kecelakaan di suatu daerah. Dalam makalah ini, peneliti melakukan studi terhadap interaksi antara kecelakaan lalu lintas, kondisi jalan, dan faktor lingkungan yang berpengaruh pada kejadian kecelakaan. Teknik data mining digunakan untuk membuat model prediksi kecelakaan menggunakan algoritma Apriori dan Support Vector Machines. Data kecelakaan di jalan raya kota Bangalore dari tahun 2014 hingga 2017 menjadi sumber data dalam penelitian ini. Hasil studi dapat memberikan manfaat bagi berbagai pihak, seperti departemen pekerjaan umum pemerintah, kontraktor, dan industri otomotif dalam merancang jalan dan kendaraan yang lebih aman.

Dalam makalah ini mengulik prediksi kemungkinan terjadinya kecelakaan berdasarkan data kecelakaan jalan yang tersedia. Pra-pemrosesan data dilakukan pada data kecelakaan jalan ini untuk mendapatkan dataset. Tahap pra-pemrosesan data dilakukan dengan pembersihan untuk menghapus nilai-nilai kosong dan tidak valid, serta normalisasi data, diikuti dengan seleksi fitur, di mana hanya fitur-fitur yang relevan dari dataset asli yang dipilih untuk dimasukkan ke dalam dataset akhir.

Dataset kemudian dikenakan berbagai teknik pertambangan data. Pemusatan kelompok dilakukan pada dataset ini. Kelompok-kelompok ini kemudian dikenakan algoritma lain seperti Support Vector Machines (SVM) dan Apriori. Karena data yang digunakan untuk studi ini memiliki distribusi yang tidak diketahui dan perlu disortir item-item yang sering dan jarang terjadi dalam dataset, SVM digunakan untuk memprediksi risiko kemungkinan terjadinya kecelakaan sementara Apriori diterapkan untuk melakukan pertambangan aturan, yaitu menghasilkan set item yang sering terjadi berdasarkan nilai dukungan dan kepercayaan yang diberikan.

Rule dibuat dengan mempertimbangkan berbagai kombinasi faktor yang telah menyebabkan kecelakaan dengan sifat dan tingkat keparahan yang berbeda di berbagai jenis jalan dan kondisi cuaca. Untuk set item yang sering terjadi, nilai support value dan confidence value yang dipilih mengimplikasikan probabilitas yang lebih tinggi dari kombinasi atribut tertentu dalam menyebabkan kecelakaan. Misalnya, berdasarkan pertambahan rule yang dilakukan, risiko kemungkinan terjadinya kecelakaan bahkan pada cuaca yang cerah di persimpangan karena kecepatan yang berlebihan tinggi dan dapat membuktikan fatal berdasarkan dataset pelatihan. Klasifikasi SVM telah digunakan untuk mengkaraktisasi setiap kejadian kecelakaan ke dalam kategori risiko tinggi atau rendah.



Gambar 2.1: Arsitektur implementasi model

Berbagai teknik pertambahan data dan teknik visualisasi eksplorasi diterapkan pada dataset kecelakaan untuk mendapatkan hasil yang diinterpretasikan. Arsitektur model yang diimplementasikan dalam makalah ini ditunjukkan dalam gambar di atas. Estimasi berbagai faktor yang terlibat dalam kecelakaan jalan membantu menentukan kontribusinya dalam menyebabkan kecelakaan. Analisis dan penelitian ini membantu dalam memberikan solusi untuk mengurangi tingkat kecelakaan dan mengurangi angka kematian.

BAB 3

METODOLOGI

3.1 Penjelasan Dataset

Dataset yang kami gunakan adalah dataset FARS (*Fatality Analysis Reporting System*). FARS adalah sensus nasional yang menyediakan Administrasi Keselamatan Lalu Lintas Jalan Raya Nasional (NHTSA), bagian dari Departemen Perhubungan AS, dengan data tentang kecelakaan lalu lintas yang fatal di Amerika Serikat. Kumpulan data FARS mencakup data tentang semua kecelakaan kendaraan bermotor yang terjadi di jalan raya umum dan mengakibatkan kematian setidaknya satu orang dalam waktu 30 hari setelah kecelakaan. Kumpulan data berisi informasi tentang karakteristik kecelakaan, kendaraan yang terlibat, dan orang yang tewas, termasuk informasi demografis, faktor terkait kecelakaan, dan informasi cedera. Kumpulan data FARS digunakan oleh peneliti, pembuat kebijakan, dan praktisi untuk menganalisis tren, mengidentifikasi faktor risiko, dan mengembangkan intervensi untuk mengurangi kematian dan cedera akibat kecelakaan kendaraan bermotor. Berikut atribut yang terdapat dalam dataset tersebut:

No.	Fitur	Deskripsi
1	STATE	Kode negara bagian tempat kejadian kecelakaan.
2	STATENAME	Nama negara bagian tempat kejadian kecelakaan.
3	ST_CASE	Nomor kasus kecelakaan lalu lintas.
4	VE_TOTAL	Total kendaraan terlibat dalam kecelakaan.
5	VE_FORMS	Jumlah kendaraan terdaftar dalam kasus kecelakaan.
6	PVH_INVL	Jumlah kendaraan pribadi yang terlibat dalam kecelakaan (termasuk sepeda motor dan sepeda).
7	PEDS	Jumlah pejalan kaki yang terlibat dalam kecelakaan.
8	PERSONS	Jumlah orang yang terlibat dalam kecelakaan (termasuk pengemudi, penumpang, dan pejalan kaki).

9	PERMVIT	Jumlah korban yang terlibat dalam kecelakaan (termasuk pengemudi, penumpang, dan pejalan kaki).
10	PERNOTMVIT	Jumlah orang yang terlibat dalam kecelakaan (termasuk pengemudi, penumpang, dan pejalan kaki).
11	COUNTY	Kode county tempat kejadian kecelakaan.
12	COUNTYNAME	Nama county tempat kejadian kecelakaan.
13	CITY	Kode kota tempat kejadian kecelakaan.
14	CITYNAME	Nama kota tempat kejadian kecelakaan.
15	DAY	Hari kejadian kecelakaan (1-31).
16	DAYNAME	Nama hari kejadian kecelakaan.
17	MONTH	Bulan kejadian kecelakaan (1-12).
18	MONTHNAME	Nama bulan kejadian kecelakaan.
19	YEAR	Tahun kejadian kecelakaan.
20	DAY_WEEK	Hari dalam seminggu kejadian kecelakaan (1-7, di mana 1 = Minggu dan 7 = Sabtu).
21	DAY_WEEKNAME	Nama hari dalam seminggu kejadian kecelakaan.
22	HOURL	Jam kejadian kecelakaan (0-23).
23	HOURNAME	Kategori waktu kejadian kecelakaan.
24	MINUTE	Menit kejadian kecelakaan (0-59).
25	MINUTENAME	Rentang menit kejadian kecelakaan (0-59).
26	NHS	Kode sistem jalan nasional tempat kejadian kecelakaan.
27	NHSNAME	Nama sistem jalan nasional tempat kejadian kecelakaan.
28	ROUTE	Kode rute tempat kejadian kecelakaan.
29	ROUTENAME	Nama rute tempat kejadian kecelakaan.
30	TWAY_ID	Identifikasi jalan tempat kejadian kecelakaan.
31	TWAY_ID2	Identifikasi tambahan jalan tempat kejadian kecelakaan.
32	RUR_URB	Kode status perkotaan atau pedesaan tempat kejadian kecelakaan.

33	RUR_URBNAME	Nama status perkotaan atau pedesaan tempat kejadian kecelakaan.
34	FUNC_SYS	Kode sistem fungsional jalan tempat kejadian kecelakaan.
35	FUNC_SYSNAME	Nama sistem fungsional jalan tempat kejadian kecelakaan.
36	RD_OWNER	Kode kepemilikan jalan tempat kejadian kecelakaan.
37	RD_OWNERNAME	Nama kepemilikan jalan tempat kejadian kecelakaan.
38	MILEPT	Posisi mil tempat kejadian kecelakaan.
39	MILEPTNAME	Nama posisi mil tempat kejadian kecelakaan.
40	LATITUDE	Koordinat lintang tempat kejadian kecelakaan.
41	LATITUDENAME	Nama koordinat lintang tempat kejadian kecelakaan.
42	LONGITUD	Koordinat bujur tempat kejadian kecelakaan.
43	LONGITUDNAME	Nama koordinat bujur tempat kejadian kecelakaan.
44	SP_JUR	Kode yurisdiksi khusus tempat kejadian kecelakaan.
45	SP_JURNAME	Nama yurisdiksi khusus tempat kejadian kecelakaan.
46	HARM_EV	Kode peristiwa utama yang menyebabkan kecelakaan.
47	HARM_EVNAME	Nama peristiwa utama yang menyebabkan kecelakaan.
48	MAN_COLL	Kode tipe tabrakan antara kendaraan yang terlibat dalam kecelakaan.
49	MAN_COLLNAME	Nama tipe tabrakan antara kendaraan yang terlibat dalam kecelakaan.
50	RELJCT1	Kode tipe persimpangan kejadian kecelakaan (1).
51	RELJCT1NAME	Nama tipe persimpangan kejadian kecelakaan (1).
52	RELJCT2	Kode tipe persimpangan kejadian kecelakaan (2).
53	RELJCT2NAME	Nama tipe persimpangan kejadian kecelakaan (2).
54	TYP_INT	Kode jenis antarmuka persimpangan.
55	TYP_INTNAME	Nama jenis antarmuka persimpangan.
56	WRK_ZONE	Kode zona kerja tempat kejadian kecelakaan.
57	WRK_ZONENAME	Nama zona kerja tempat kejadian kecelakaan.

58	REL_ROAD	Kode hubungan jalan tempat kejadian kecelakaan dengan jalan lain.
59	REL_ROADNAME	Nama hubungan jalan tempat kejadian kecelakaan dengan jalan lain.
60	LGT_COND	Kode kondisi pencahayaan saat kejadian kecelakaan.
61	LGT_CONDNAME	Nama kondisi pencahayaan saat kejadian kecelakaan.
62	WEATHER1	Kode kondisi cuaca utama saat kejadian kecelakaan.
63	WEATHER1NAME	Nama kondisi cuaca utama saat kejadian kecelakaan.
64	WEATHER2	Kode kondisi cuaca tambahan saat kejadian kecelakaan.
65	WEATHER2NAME	Nama kondisi cuaca tambahan saat kejadian kecelakaan.
66	WEATHER	Kode kondisi cuaca keseluruhan saat kejadian kecelakaan.
67	WEATHERNAME	Nama kondisi cuaca keseluruhan saat kejadian kecelakaan.
68	SCH_BUS	Kode indikator apakah ada bus sekolah yang terlibat.
69	SCH_BUSNAME	Nama indikator apakah ada bus sekolah yang terlibat.
70	RAIL	Kode indikator apakah ada kereta api yang terlibat.
71	RAILNAME	Nama indikator apakah ada kereta api yang terlibat.
72	NOT_HOUR	Jam laporan kecelakaan diterima oleh pihak berwenang.
73	NOT_HOURNAME	Kategori waktu jam laporan kecelakaan.
74	NOT_MIN	Menit laporan kecelakaan diterima oleh pihak berwenang.
75	NOT_MINNAME	Rentang menit laporan kecelakaan diterima oleh pihak berwenang (0-59).
76	ARR_HOUR	Jam kedatangan pihak berwenang di tempat kejadian kecelakaan.
77	ARR_HOURNAME	Kategori waktu kedatangan pihak berwenang di tempat kejadian kecelakaan.

78	ARR_MIN	Menit kedatangan pihak berwenang di tempat kejadian kecelakaan.
79	ARR_MINNAME	Rentang menit kedatangan pihak berwenang di tempat kejadian kecelakaan (0-59).
80	HOSP_HR	Jam kedatangan di rumah sakit.
81	HOSP_HRNAME	Kategori waktu kedatangan di rumah sakit.
82	HOSP_MN	Menit kedatangan kedatangan di rumah sakit.
83	HOSP_MNNAME	Rentang menit kedatangan kedatangan di rumah sakit (0-59).
84	CF1	Faktor penyebab utama kecelakaan.
85	CF1NAME	Nama faktor penyebab utama kecelakaan.
86	CF2	Faktor penyebab tambahan kecelakaan.
87	CF2NAME	Nama faktor penyebab tambahan kecelakaan.
88	CF3	Nama faktor penyebab tambahan kecelakaan.
89	CF3NAME	Nama faktor penyebab tambahan kecelakaan.
90	FATALS	Jumlah kematian akibat kecelakaan.
91	DRUNK_DR	Jumlah pengemudi yang dilaporkan mabuk atau terpengaruh alkohol.

Tabel 3.2: Data Dictionary

3.2 Teknik Analisis Data

Metode analisis data dalam tugas ini menggunakan model Regresi Linier. Model ini diuji menggunakan metrik evaluasi *Mean Squared Error* dan *R-Squared*. Pemodelan dilakukan dengan memilih beberapa atribut yang memiliki korelasi tertinggi dengan label FATALS (jumlah angka kematian) di *threshold* tertentu.

3.2.1 Regresi Linier

Regresi linier adalah salah satu metode statistik yang digunakan untuk memodelkan hubungan antara variabel dependen (variabel target) dan satu atau lebih variabel independen (variabel prediktor). Tujuan dari regresi linier adalah untuk memprediksi nilai

variabel dependen berdasarkan nilai-nilai variabel independen yang diketahui. Model regresi linier memiliki bentuk matematis yang sederhana, yaitu:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon \quad (3.1)$$

Dimana:

- Y adalah variabel dependen yang ingin diprediksi.
- $X_1, X_2, \dots, X_n$ adalah variabel independen yang digunakan sebagai prediktor.
- $\beta_0, \beta_1, \beta_2, \dots, \beta_n$ adalah koefisien regresi yang menunjukkan seberapa besar pengaruh variabel independen terhadap variabel dependen.
- ϵ adalah kesalahan acak atau residual, yang merupakan perbedaan antara nilai aktual dan nilai yang diprediksi oleh model.

Koefisien regresi ($\beta_0, \beta_1, \beta_2, \dots, \beta_n$) diperoleh melalui proses estimasi yang disebut estimasi regresi. Tujuan dari estimasi regresi adalah untuk menemukan nilai-nilai koefisien regresi yang paling sesuai dengan data yang ada, yaitu nilai-nilai yang menghasilkan prediksi yang paling akurat. Untuk melakukan estimasi regresi, terdapat berbagai teknik yang dapat digunakan, seperti metode kuadrat terkecil (*least squares method*) yang paling umum. Metode ini meminimalkan jumlah kuadrat dari selisih antara nilai aktual dan nilai yang diprediksi oleh model. Dalam hal ini, regresi linier sering disebut sebagai regresi linier kuadrat terkecil atau regresi linier berganda ketika melibatkan lebih dari satu variabel independen. Setelah model regresi linier dikembangkan, evaluasi model dilakukan untuk memeriksa seberapa baik model tersebut cocok dengan data. Evaluasi ini melibatkan pengujian asumsi regresi, seperti asumsi tentang normalitas residual, homoskedastisitas, dan tidak adanya multikolinearitas. Regresi linier dapat digunakan untuk berbagai tujuan, termasuk prediksi dan penjelasan. Dalam prediksi, model regresi linier dapat digunakan untuk memprediksi nilai variabel dependen baru berdasarkan nilai-nilai variabel independen yang diketahui. Dalam penjelasan, model regresi linier membantu mengidentifikasi hubungan dan pengaruh variabel independen terhadap variabel dependen. Model regresi linier dapat dievaluasi menggunakan berbagai metrik, seperti R-squared (koefisien determinasi), nilai F, uji signifikansi koefisien regresi individual, dan uji MSE (*Mean Squared Error*). R-squared menggambarkan proporsi variasi dalam variabel dependen yang dapat dijelaskan oleh model regresi, sedangkan nilai F menguji signifikansi keseluruhan

model. Uji signifikansi koefisien regresi individual digunakan untuk menentukan apakah koefisien setiap variabel independen memiliki kontribusi yang signifikan terhadap variabel dependen. Uji MSE digunakan untuk mengukur sejauh mana prediksi model regresi linier berbeda dari nilai sebenarnya. Namun, penting untuk diingat bahwa model regresi linier memiliki asumsi dan batasan tertentu. Misalnya, model ini mengasumsikan adanya hubungan linier antara variabel independen dan variabel dependen. Jika hubungan tersebut tidak linier, model regresi linier mungkin tidak menghasilkan prediksi yang akurat. Selain itu, model ini juga rentan terhadap asumsi yang dilanggar, seperti adanya multikolinearitas atau heteroskedastisitas. Oleh karena itu, penting untuk melakukan analisis yang cermat dan mempertimbangkan metode regresi lainnya jika asumsi model tidak terpenuhi.

3.2.1.1 Metrik Evaluasi

Model regresi linier dapat dievaluasi menggunakan berbagai metrik, seperti R-squared (koefisien determinasi), nilai F, uji signifikansi koefisien regresi individual, dan uji MSE (*Mean Squared Error*). R-squared menggambarkan proporsi variasi dalam variabel dependen yang dapat dijelaskan oleh model regresi, sedangkan nilai F menguji signifikansi keseluruhan model. Uji signifikansi koefisien regresi individual digunakan untuk menentukan apakah koefisien setiap variabel independen memiliki kontribusi yang signifikan terhadap variabel dependen. Lalu, uji MSE digunakan untuk mengukur sejauh mana prediksi model regresi linier berbeda dari nilai sebenarnya. Metrik yang digunakan dalam pengerjaan tugas ini adalah MSE dan R-Squared.

3.2.1.1.1 *Mean Squared Error* (MSE)

Metrik MSE (*Mean Squared Error*) merupakan salah satu metrik evaluasi yang umum digunakan dalam regresi linier dan regresi lainnya. MSE mengukur rata-rata dari selisih kuadrat antara nilai aktual dan nilai yang diprediksi oleh model. Untuk menghitung MSE, langkah-langkahnya sebagai berikut:

1. Pertama, untuk setiap data observasi, prediksi nilai menggunakan model regresi linier.
2. Selanjutnya, hitung selisih antara nilai aktual dan nilai prediksi. Kuadratkan setiap selisih.

3. Jumlahkan semua selisih kuadrat.
4. Bagi hasil penjumlahan tersebut dengan jumlah total data observasi.

Secara matematis, MSE dapat dinyatakan dengan rumus berikut:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (3.2)$$

Dimana:

- MSE adalah Mean Squared Error.
- n adalah jumlah total data observasi.
- y_i adalah nilai aktual.
- $\hat{y}_i$ adalah nilai yang diprediksi oleh model.
- MSE memiliki interpretasi bahwa semakin rendah nilainya, semakin baik kinerja model regresi linier. Nilai MSE yang rendah menunjukkan bahwa model memiliki tingkat kesalahan prediksi yang lebih kecil atau lebih akurat.

MSE memiliki keuntungan dalam mengukur kesalahan prediksi dengan memperhitungkan perbedaan antara nilai aktual dan nilai prediksi. Dalam banyak kasus, MSE lebih sensitif terhadap nilai-nilai prediksi yang jauh dari nilai aktual, karena selisih kuadrat membesar secara eksponensial seiring dengan peningkatan perbedaan antara nilai aktual dan nilai prediksi.

Namun, MSE juga memiliki kelemahan yaitu besarnya unit dalam kuadrat, yang mungkin sulit untuk diinterpretasikan secara langsung. Sebagai alternatif, terdapat metrik evaluasi lain seperti RMSE (*Root Mean Squared Error*), yang merupakan akar kuadrat dari MSE dan memiliki unit yang sama dengan variabel dependen, sehingga lebih mudah dipahami.

3.2.1.1.2 *R-Squared*

Metrik *R-Squared* (R^2) atau juga dikenal sebagai koefisien determinasi, digunakan untuk mengevaluasi kualitas model regresi linier dan mengukur sejauh mana variabilitas dalam variabel dependen dapat dijelaskan oleh variabel independen dalam model. *R-Squared* mengindikasikan proporsi variasi dalam variabel dependen yang dapat dijelaskan oleh model regresi linier. *R-Squared* memiliki rentang nilai antara 0 hingga 1, dimana:

- $R\text{-Squared} = 0$ menunjukkan bahwa model tidak dapat menjelaskan variasi apa pun dalam variabel dependen dan hanya memperlihatkan kesalahan prediksi.
- $R\text{-Squared} = 1$ menunjukkan bahwa model dapat menjelaskan seluruh variasi dalam variabel dependen dan memberikan prediksi yang sempurna.

Untuk menghitung $R\text{-Squared}$, langkah-langkahnya sebagai berikut:

1. Pertama, hitung total variabilitas dalam variabel dependen dengan menghitung jumlah kuadrat selisih antara nilai aktual dan rata-rata nilai aktual. Hal ini disebut sebagai *Total Sum of Squares* (SST).

$$SST = \sum_i (y_i - \bar{y})^2 \quad (3.3)$$

Dimana:

- y_i adalah nilai aktual.
 - $\bar{y}$ adalah nilai yang diprediksi oleh model.
2. Selanjutnya, hitung variabilitas yang tidak dapat dijelaskan oleh model regresi linier, yang dikenal sebagai *Sum of Squares Residual* (SSR). SSR adalah jumlah kuadrat selisih antara nilai aktual dan nilai yang diprediksi oleh model.

$$SSR = \sum_i (y_i - \hat{y}_i)^2 \quad (3.4)$$

Dimana:

- y_i adalah nilai aktual.
 - $\hat{y}_i$ adalah nilai yang diprediksi oleh model.
3. Terakhir, hitung $R\text{-Squared}$ menggunakan rumus berikut:

$$R\text{-Squared} = 1 - (SSR / SST)$$

atau dapat juga dituliskan sebagai:

$$R\text{-Squared} = 1 - (\text{Varian Error} / \text{Varian Total})$$

$R\text{-Squared}$ dapat diinterpretasikan sebagai proporsi variasi dalam variabel dependen yang dapat dijelaskan oleh model regresi linier. Semakin tinggi nilai $R\text{-Squared}$,

semakin baik model dalam menjelaskan variasi dalam variabel dependen. Namun, penting untuk diingat bahwa *R-Squared* tidak memberikan informasi tentang signifikansi statistik atau kausalitas variabel independen terhadap variabel dependen.

R-Squared juga dapat memiliki nilai negatif dalam beberapa kasus ketika model regresi linier yang digunakan tidak lebih baik daripada menggunakan rata-rata sebagai prediksi konstan.

3.2.2 Regresi Random Forest

Random Forest Regressor adalah algoritma yang digunakan dalam pemodelan regresi untuk memprediksi nilai variabel target berdasarkan sekumpulan variabel prediktor. Ini menggunakan pendekatan ensemble learning, di mana beberapa pohon keputusan (decision trees) dikombinasikan untuk membentuk model yang lebih kuat.

Penggunaan Random Forest Regressor memiliki beberapa kelebihan. Pertama, itu dapat menangani dataset dengan jumlah variabel yang besar dan kompleks. Algoritme ini mampu menangani data yang memiliki banyak fitur dan mengatasi masalah dimensi tinggi. Kedua, Random Forest Regressor memiliki kemampuan untuk menangani data yang mengandung missing values dan outlier. Ini membuatnya lebih robust dalam menghadapi data yang tidak sempurna. Ketiga, algoritme ini mengurangi risiko overfitting karena mengambil rata-rata prediksi dari beberapa pohon keputusan.

3.2.2.1 Cara kerja


Random Forest didasari dari konsep decision tree, dimana decision tree yang independen dibangun dari subsampling acak dari dataset pelatihan. Setiap decision tree dalam Random Forest melakukan prediksi berdasarkan subset fitur yang dipilih secara acak dari semua fitur yang tersedia. Dalam hal ini, Random Forest secara efektif mengatasi masalah overfitting dan meningkatkan generalisasi model.

Selain itu, Random Forest juga melakukan penggabungan prediksi dari semua decision tree yang terbentuk. Dalam kasus klasifikasi, ini dilakukan dengan menggunakan voting mayoritas dari prediksi decision tree. Sedangkan dalam kasus regresi, rata-rata prediksi decision tree digunakan untuk menghasilkan prediksi akhir.

Proses pelatihan dalam Random Forest melibatkan membuat banyak decision tree yang berbeda pada subsampling acak dari dataset pelatihan. Setiap decision tree dilatih dengan

menggunakan algoritme pembelajaran pohon keputusan yang biasa, di mana setiap pohon memilih fitur secara acak untuk membangun aturan keputusan. Dengan membagi dataset pelatihan menjadi subset yang lebih kecil dan mengambil subset fitur yang acak, Random Forest mengurangi risiko overfitting yang dapat terjadi saat menggunakan satu decision tree tunggal yang sangat dalam.

Setelah decision tree terbentuk, prediksi dilakukan dengan menggunakan kombinasi hasil prediksi dari semua decision tree. Dalam kasus klasifikasi, hasil prediksi dari setiap decision tree dihitung dan hasil yang paling umum menjadi prediksi akhir. Dalam kasus regresi, rata-rata prediksi dari semua decision tree digunakan sebagai prediksi akhir.



Gambar 3.1: Diagram cara kerja regresi random forest

BAB 4

EKSPERIMEN DAN EVALUASI


Bab ini menjelaskan tentang interpretasi dari grafik atau tabel yang dibuat dan bagaimana grafik atau tabel tersebut dapat menjawab *research question*.

4.1 Eksperimen dan Evaluasi

4.1.1 Korelasi Kecelakaan yang Melibatkan Alkohol dengan Waktu Kejadian




Gambar 4.1: Persebaran data kecelakaan yang melibatkan alkohol pada bulan yang berbeda



Gambar 4.2: Variasi jumlah kecelakaan yang melibatkan alkohol yang pada tanggal yang berbeda

Tingkat kecelakaan yang disebabkan oleh pengemudi mabuk mengalami peningkatan mulai dari jam 3 sore dan mencapai puncaknya pada sekitar jam 8 malam dan jam 2 pagi, kemudian kembali turun sampai jam 10 pagi. Jumlah kecelakaan yang disebabkan oleh pengemudi mabuk dalam satu minggu mengalami peningkatan pada hari Jumat sampai dengan Minggu. Pada kecelakaan yang melibatkan pengemudi mabuk dalam rentang satu bulan, tidak terlihat pola khusus dari banyaknya kecelakaan yang terjadi. Berdasarkan grafik, kecelakaan yang melibatkan pengemudi mabuk mengalami kenaikan pada bulan 4 sampai 7, turun dan berfluktuasi setelahnya, dan mengalami kenaikan lagi. Kecelakaan yang terjadi dalam jangka perbulan pada tanggal yang berbeda menunjukkan suatu pola parabola dengan titik ekstrem pada tanggal 11-13 sehingga kemungkinan ada hubungan antara tanggal terjadinya kecelakaan dengan kecelakaan akibat mabuk.

4.1.1.1 Hasil One-Way ANOVA




Gambar 4.3: Salah satu grafik residual hasil ANOVA Test yang menunjukkan antar kecelakaan mabuk dengan jam terjadinya kecelakaan

Hasil perhitungan test one-way ANOVA pada semua variabel di atas mengindikasikan bahwa untuk ANOVA test, belum tentu ada hubungan yang signifikan antara banyak pengemudi yang terlibat kecelakaan mabuk dengan jam terjadinya kecelakaan yang disebabkan oleh mabuk karena residual yang tidak terdistribusi secara normal. Hal ini mengakibatkan hasil ANOVA test yang diberikan bisa jadi tidak valid meskipun ada indikasi dari p-value yang lebih kecil dari 0.05 bahwa kedua data berhubungan.

4.1.1.2 Evaluasi Data


Dari Beberapa grafik seperti salah satunya jumlah kecelakaan akibat mabuk pada tanggal yang berbeda, dapat dilihat pola tertentu yang terjadi, grafik membentuk pola serupa grafik parabola dengan titik ekstrem terendah pada tanggal 13, hal ini mengindikasikan adanya kaitan tertentu antara kecelakaan yang disebabkan oleh mengemudi mabuk dengan tanggal terjadinya kecelakaan, Namun hasil perhitungan ANOVA pada test ini menunjukkan residual yang tidak terdistribusi secara normal sehingga tidak dapat diambil kesimpulan apakah pola yang terjadi pada grafik benar-benar ada hubungannya satu sama lain atau hanya kebetulan semata.

4.1.2 Distribusi Fatalitas kecelakaan yang terjadi pada jenis jalan dan daerah berbeda




Gambar 4.4: Perbandingan total fatalitas yang terjadi antara Urban dan Rural

Berdasarkan data yang didapatkan dari analisis, total fatalitas yang terjadi pada Puerto Rico didominasi oleh kasus yang berasal dari rural area. Namun, rata-rata dari jumlah fatalitas yang terjadi pada kedua area sama, hal ini berarti peluang terjadinya kecelakaan antara rural dan urban area di Puerto Rico hampir sama tetapi kecelakaan yang terjadi pada daerah rural lebih banyak terjadi frekuensinya dibanding kecelekaan yang terjadi pada urban area



Gambar 4.5: Rata-rata fatalitas yang terjadi pada tipe jalan yang berbeda



Gambar 4.6: Total fatalitas yang terjadi pada tipe jalan yang berbeda

Berdasarkan data jumlah fatalitas yang terjadi, fatalitas yang terjadi pada jalan dengan tipe Principal Arterial - Other terjadi dengan frekuensi yang lebih banyak namun dengan

rata-rata kejadian yang sama dengan tipe jalan lain sehingga kemungkingna besar peluang terjadinya kecelakaan pada tipe jalan yang berbeda tersebut sama. Sedikit frekuensi fatalitas yang terjadi pada tipe jalan Freeway and Expressway sehingga sulit untuk mengambil kesimpulan apakah tipe jalan ini memiliki rata-rata fatalitas yang sebenarnya sama atau memang lebih tinggi.

4.1.2.1 Evaluasi Data

Secara keseluruhan, kebanyakan kecelakaan fatal yang terjadi di puerto rico terjadi pada daerah Rural dan pada daerah Principal Arterial - Other. Kurangnya data pada kecelakaan yang terjadi pada daerah bertipe Freeway dan Expressway membuat susahnya ditentukan apakah memang jarang ada kecelakaan yang terjadi pada daerah tersebut atau sedikitnya akses pengguna pada daerah tersebut sehingga kecilnya volume kendaraan yang melintas memperkecil peluang terjadinya kecelakaan

4.1.3 Faktor-faktor yang berpengaruh besar dalam kecelakaan yang melibatkan pejalan kaki dan seberapa jauh faktor-faktor ini dapat memprediksi jumlah pejalan kaki yang terlibat?

4.1.3.1 Faktor-faktor yang berpengaruh besar dalam kecelakaan yang melibatkan pejalan kaki

4.1.3.1.1 Eksperimen

Untuk memastikan apakah suatu data kecelakaan melibatkan pejalan kaki, dapat diamati nilai PEDS, yang artinya jumlah orang yang berjalan kaki, apakah memiliki nilai lebih besar dari 0. Sebelum digunakan untuk mengukur korelasi dengan variabel lain, dibentuk dulu variabel baru bernama PEDS_BINARY yang nilainya 1 jika PEDS memiliki nilai lebih besar dari 0, 0 apabila nilainya 0.

Setelah itu, dibentuk matriks korelasi dengan menggunakan metode Pearson untuk melihat korelasi antara variabel yang bertipe numerik. Koefisien korelasi Pearson itu adalah ukuran statistik yang digunakan untuk mengukur kekuatan dan arah hubungan linier antara dua variabel. Rentang nilai koefisien ini berkisar antara -1 hingga +1.

4.1.3.1.2 Evaluasi

Tabel 4.1 menjabarkan correlation coefficient yang ada di dataframe. Kita bisa mengesampingkan PEDS_BINARY, PEDS dan PERNOTMVIT dengan berbagai macam alasan. Terlihat variabel-variabel tersebut masih dalam topik pedestrian. Selain itu, nilai korelasi variabel tersebut sangat dekat dengan 1, yaitu dalam rentang 0.9. Hal ini menunjukkan bahwa variabel tersebut redundan.

Dari semua korelasi positif, nilai tertinggi terdapat pada variabel RUR_URB dengan koefisien korelasi 0.151759. Sedangkan dari semua korelasi negatif, nilai-nilai tertinggi terdapat pada variabel REL ROAD dengan koefisien korelasi -0.406187, VE FORMS dengan -0.419271, dan HARM EV dengan -0.483134.

Tabel 4.1: Koefisien Korelasi

Variabel	Koefisien Korelasi Pearson
PEDS_BINARY	1.000000
PEDS	0.944268
PERNOTMVIT	0.926924
RUR_URB	0.151759
CF1	0.093103
LATITUDE	0.074836
LONGITUDE	0.074708
NHS	0.058400
LGT_COND	0.043030
CF2	0.041539
SCH_BUS	0.030528
DAY_WEEK	0.029524
DAY	0.027248
DAYNAME	0.027248
CITY	0.019804
RD_OWNER	0.016224
MINUTE	0.015789
MINUTENAME	0.015789
HOURL	0.014549
ROUTE	0.010122
MILEPT	-0.004728
PVH_INVL	-0.005558
RELJCT1	-0.017536
TYP_INT	-0.020056
ST_CASE	-0.020206
RELJCT2	-0.024014
WRK_ZONE	-0.024096
FUNC_SYS	-0.026262
MONTH	-0.032306
COUNTY	-0.038043
WEATHER	-0.050287
WEATHER1	-0.052295
YEAR	-0.052555
NOT_HOUR	-0.058972
ARR_MIN	-0.059318
ARR_HOUR	-0.059839
HOSP_HR	-0.069162
HOSP_MN	-0.070085
NOT_MIN	-0.073873
FATALS	-0.094363
PERMVIT	-0.297925
PERSONS	-0.298970
DRUNK_DR	-0.368848
VE_TOTAL	-0.390707
MAN_COLL	-0.398293
REL_ROAD	-0.406187
VE_FORMS	-0.419271
HARM_EV	-0.483134

4.1.3.2 Seberapa jauh faktor-faktor ini dapat memprediksi jumlah pejalan kaki yang terlibat?

4.1.3.2.1 Eksperimen

Didapatkan dari bagian sebelumnya, variabel yang dipakai adalah HARM_EV, VE_FORMS, MAN_COLL. Maksud dari variabel tersebut adalah sebagai berikut: kode peristiwa utama yang menyebabkan kecelakaan, jumlah kendaraan terdaftar dalam kasus kecelakaan, kode tipe tabrakan antara kendaraan yang terlibat dalam kecelakaan. Untuk melakukan prediksi, digunakan random forest regressor.

4.1.3.2.2 Evaluasi

Mean Squared Error: 0.11549476937127988

R-squared: -0.020747103577653858

Untuk mengevaluasi kinerja model, kita perlu melihat beberapa metrik. Dalam kasus ini, kita memiliki Mean Squared Error (MSE) dan R-squared untuk menilai kualitas prediksi model. Disini, MSE mengukur seberapa dekat prediksi model dengan nilai sebenarnya. Semakin rendah MSE, semakin baik performa model. Dalam kasus ini, MSE memiliki nilai 0.11549476937127988. Ini menunjukkan bahwa rata-rata kuadrat perbedaan antara nilai prediksi dan nilai sebenarnya adalah sekitar 0.115. Semakin rendah nilai MSE, semakin akurat prediksi model.

R-squared mengukur seberapa baik model dapat menjelaskan variasi dalam data. Rentang nilai R-squared adalah antara 0 hingga 1. Nilai negatif R-squared - 0.020747103577653858 menunjukkan bahwa model tidak memberikan penjelasan yang baik terhadap variasi dalam data, dan model mungkin tidak cocok untuk dataset yang digunakan.

4.1.4 Atribut-atribut yang Dapat Memprediksi Angka Kematian

Tabel berikut berisi koefisien korelasi setiap atribut dengan atribut FATALS.

Tabel 4.2: Koefisien Korelasi

Atribut	Koefisien Korelasi
PERSONS	3.248774e-01
PERMVIT	3.248774e-01
RUR_URB	1.873957e-01
TYP_INT	1.584137e-01
RELJCT1	.584137e-01
DAY	1.441160e-01
RELJCT2	1.391402e-01
HOURL	1.377921e-01
YEAR	1.235210e-01
DRUNK_DR	1.165936e-01
HOSP_HR	1.135031e-01
HOSP_MN	1.135031e-01
DAY_WEEK	1.072282e-01
MINUTE	9.444559e-02
ST_CASE	9.015107e-02
NHS	8.765281e-02
CITY	8.749774e-02
PERNOTMVIT	8.571759e-02
PEDS	8.571759e-02
VE_FORMS	7.907369e-02
VE_TOTAL	7.111543e-02
REL_ROAD	6.744799e-02
ARR_MIN	6.438231e-02
ARR_HOUR	6.419455e-02
NOT_HOUR	6.418017e-02
NOT_MIN	6.380962e-02
MONTH	5.585228e-02
WEATHER	4.503189e-02
WEATHER1	4.503189e-02
HARM_EV	3.996549e-02
RD_OWNER	3.978951e-02
ROUTE	3.699747e-02
MAN_COLL	1.825643e-02
PVH_INV	1.350957e-02
FUNC_SYS	1.256742e-02
LGT_COND	1.153599e-02
MILEPT	9.302738e-03
LATITUDE	6.260739e-17
COUNTY	NaN
LONGITUD	NaN
WRK_ZONE	NaN
SCH_BUS	NaN
CF1	NaN
CF2	NaN

Dalam tabel korelasi di atas, terdapat beberapa atribut yang memiliki korelasi yang relatif tinggi dengan label FATALS (angka kematian dalam kecelakaan). Atribut-atribut tersebut adalah:

1. PERSONS: Atribut ini memiliki korelasi positif sebesar 0.324 dengan FATALS. Hal ini menunjukkan bahwa semakin banyak orang yang terlibat dalam kecelakaan, kemungkinan angka kematian juga akan meningkat.
2. PERMVIT: Atribut ini juga memiliki korelasi positif sebesar 0.324 dengan FATALS. PERMVIT mengindikasikan jumlah korban jiwa dalam kecelakaan, sehingga semakin banyak korban jiwa, semakin tinggi angka kematian.
3. RUR_URB: Atribut ini memiliki korelasi positif sebesar 0.187 dengan FATALS, tidak sekuat PERSONS dan PERMVIT. RUR_URB menggambarkan apakah kecelakaan terjadi di daerah perkotaan atau pedesaan. Korelasi positif menunjukkan bahwa kecelakaan di daerah perkotaan mungkin memiliki angka kematian yang lebih tinggi dibandingkan kecelakaan di pedesaan.

Karena *threshold* yang digunakan sebesar 0.3, maka dipilih atribut **PERSONS** dan **PERMVIT** sebagai *predictor*.

4.1.4.1 Evaluasi Model

Mean Squared Error: 0.03774467813612312

R-squared: 0.0

Berdasarkan hasil evaluasi ini, diketahui bahwa model memiliki kesalahan prediksi yang relatif kecil ($MSE = 0.0377$) ini menunjukkan bahwa model memiliki tingkat kesalahan yang rendah dalam memprediksi angka kematian dalam kecelakaan. Dan juga, atribut-atribut yang digunakan dalam model tidak mampu menjelaskan variasi angka kematian dalam kecelakaan ($R^2 = 0$). Hal ini menunjukkan bahwa model yang digunakan tidak cocok atau tidak cukup kuat dalam memprediksi angka kematian.

BAB 5

KESIMPULAN DAN SARAN

Pada bab ini, Penulis akan memaparkan kesimpulan penelitian dan saran untuk penelitian berikutnya.

5.1 Kesimpulan

Berikut ini adalah kesimpulan terkait pekerjaan yang dilakukan dalam penelitian ini:

1. Garis besar topik bahasan

Kecelakaan lalu lintas adalah peristiwa yang tidak diduga dan melibatkan kendaraan bermotor di jalan raya. Faktor utama yang menyebabkan kecelakaan antara lain kondisi jalan, cuaca, kendaraan, dan kesalahan manusia seperti mengemudi dalam keadaan mabuk atau terpengaruh obat-obatan.

Diperlukan analisis data mengenai kecelakaan dan faktor penyebabnya agar dapat mengambil tindakan preventif yang dapat mengurangi kecelakaan di masa depan. Machine learning dapat membantu menemukan pola dari kecelakaan yang terjadi dan memungkinkan dilakukannya pencegahan tambahan seperti pengaturan jam lalu lintas atau penerapan larangan tertentu. Model machine learning juga dapat membantu mengidentifikasi faktor yang paling berpengaruh dan memprediksi keparahan kecelakaan di masa depan. Penelitian ini bertujuan untuk mengevaluasi apakah hasil analisis menggunakan machine learning memiliki kemiripan dengan faktor penyebab kecelakaan yang sudah dipaparkan sebelumnya. Selain itu, penelitian ini juga bertujuan untuk mencari pola waktu dan lokasi kecelakaan sehingga dapat dilakukan pencegahan atau penanganan tambahan.

2. Kecelakaan akibat mabuk dengan waktu kejadian

Terjadinya kecelakaan yang disebabkan oleh pengemudi mabuk jelas menunjukan pola terkait dengan waktu kecelakaan itu terjadi, namun tidak bisa dibuktikan apakah memang benar ada korelasi atau hanya kebetulan saja karena distribusi residu dari kesemua ANOVA test yang dilakukan tidak terdistribusi secara normal.

3. Persebaran kecelakaan fatal pada daerah dan jalan berbeda

Sebagian besar kecelakaan fatal yang terjadi di Puerto Rico terjadi pada daerah Urban dan terjadi pada Functional system principal arterial, beberapa daerah seperti Freeway dan Expressway memiliki kadar kecelakaan yang jauh lebih sedikit dibandingkan jenis jalan yang lainnya sehingga tidak bisa dibandingkan apakah memang daerah tersebut memiliki tingkat fatalities yang sama atau lebih rendah. Namun dari data ini, kita bisa menyimpulkan bahwa daerah-daerah yang fatalities nya lebih besar memerlukan pengawasan atau tindakan pencegahan tambahan

4. Faktor yang memengaruhi banyaknya jumlah pejalan kaki terkait sebuah kecelakaan

Faktor yang memengaruhi banyaknya jumlah pejalan kaki terkait sebuah kecelakaan dicari dengan menggunakan metode korelasi Pearson. Dari semua korelasi positif, nilai tertinggi terdapat pada variabel RUR_URB dengan koefisien korelasi 0.151759. Sedangkan dari semua korelasi negatif, nilai-nilai tertinggi terdapat pada variabel REL_ROAD (kode hubungan jalan tempat kejadian kecelakaan dengan jalan lain) dengan koefisien korelasi -0.406187, VE_FORMS (jumlah kendaraan terdaftar dalam kasus kecelakaan) dengan nilai -0.419271, dan HARM_EV (kode peristiwa utama yang menyebabkan kecelakaan) dengan nilai -0.483134. Nilai-nilai tertinggi koefisien korelasi Pearson terhadap jumlah pejalan kaki ini bernilai negatif, yang artinya peningkatan satu variabel dikaitkan dengan penurunan variabel lainnya.

5. Model prediksi jumlah pejalan kaki terkait sebuah kecelakaan

Model random forest regressor untuk memprediksi banyaknya jumlah pejalan kaki yang terlibat sebuah kecelakaan menghasilkan Mean Squared Error (MSE) yang cukup rendah (0.115) namun dengan nilai R-squared yang negatif (-0.02) menunjukkan bahwa model tidak memberikan penjelasan yang baik terhadap variasi dalam data, dan model mungkin tidak cocok untuk dataset yang digunakan.

6. Atribut-atribut yang mempengaruhi angka kematian

Berdasarkan nilai koefisien korelasi setiap atribut dengan label FATALS, diketahui bahwa untuk threshold sebesar 0.3, atribut PERSONS dan PERMVIT yang masing-masing memiliki koefisien korelasi sebesar 0.324 dapat dijadikan sebagai *predictor* untuk memprediksi angka kematian di suatu kecelakaan. lalu, dari hasil evalu-

asi model regresi linier dengan dua atribut tersebut sebagai *predictor*, didapat nilai MSE sebesar 0.0377 dan R^2 sebesar 0. Meskipun didapat nilai MSE cukup rendah, nilai R^2 yang sangat rendah menunjukkan bahwa model yang digunakan tidak mampu menjelaskan variasi dalam data dengan baik. Hal ini bisa disebabkan oleh atribut-atribut yang digunakan tidak memiliki korelasi yang cukup kuat dengan angka kematian dalam kecelakaan, atau mungkin model yang digunakan perlu diperbaiki atau disesuaikan dengan data yang lebih tepat.

5.2 Saran

Berdasarkan hasil penelitian ini, berikut ini adalah saran untuk pengembangan penelitian berikutnya:

1. Perlu pertimbangan ulang terhadap atribut yang digunakan: Melihat bahwa nilai R^2 sangat rendah, saran pertama adalah untuk mempertimbangkan kembali atribut-atribut yang digunakan dalam model. Mungkin ada atribut lain yang memiliki korelasi yang lebih kuat dengan angka kematian dalam kecelakaan. Analisis tambahan, seperti analisis korelasi atau eksplorasi data lebih lanjut, dapat membantu dalam memilih atribut yang lebih relevan dan memiliki hubungan yang lebih signifikan dengan label yang diprediksi.
2. Penambahan atribut atau fitur baru: Selain mempertimbangkan ulang atribut yang ada, ada kemungkinan untuk menambahkan atribut atau fitur baru yang relevan dalam memprediksi angka kematian dalam kecelakaan. Misalnya, data tentang kondisi jalan, kecepatan kendaraan, atau jenis kendaraan dapat memberikan wawasan tambahan dalam memahami faktor-faktor yang berkontribusi terhadap angka kematian. Eksplorasi lebih lanjut terhadap data yang tersedia dapat membantu dalam menemukan atribut-atribut baru yang dapat meningkatkan performa prediksi.
3. Evaluasi model yang digunakan: Model yang digunakan dalam analisis ini mungkin perlu dievaluasi kembali. Model yang lebih kompleks atau metode prediksi yang berbeda, seperti regresi non-linear atau model machine learning, dapat digunakan untuk meningkatkan kualitas prediksi. Pemilihan model yang sesuai dan penerapan teknik yang lebih maju dapat membantu meningkatkan performa prediksi dan menjelaskan lebih banyak variasi dalam data.

4. Penggunaan dataset yang lebih variatif: Pembatasan data yang digunakan pada Puerto Rico saja menimbulkan data yang terlalu homogenik, kurang variatif menyebabkan kurangnya jumlah data atau eksample untuk diamati pada beberapa jenis kasus
5. Penggunaan data dari situs lain: banyak data yang didapatkan dari dataset ini yang memiliki data unknown, unspecified atau tidak dirilis atas alasan tertentu yang menyebabkan sulitnya data jika digunakan dalam proses prediksi karena berpotensi menimbulkan ketidakakuratan, bisa diatasi dengan penggunaan data dari situs lain agar hasil yang didapat lebih informatif

DAFTAR REFERENSI

LAMPIRAN 1